

Diagnóstico temporal y diseño de validación

Fundamentos para estudiar el notebook 05

Índice

1	Propósito del diagnóstico	4
2	Notación y estructura de las matrices	4
2.1	Alineación	4
2.2	Controles estructurales	4
3	Calendario semanal y cobertura	5
3.1	Etiqueta y días incluidos	5
3.2	Regularidad del calendario	5
3.3	Semanas parcialmente cubiertas	5
4	Fechas de los archivos y consolidación	6
4.1	Tres fechas con funciones diferentes	6
4.2	Consistencia temporal	6
4.3	Retrasos, revisiones y extremos recientes	6
4.4	Años completos y datos consolidados	6
5	Máscaras de admisión y márgenes	7
5.1	Periodo de estudio	7
5.2	Definición de una máscara	7
5.3	Conservar fechas y distinguir estados del dato	7
6	Ceros y rachas	8
6.1	Frecuencia de ceros	8
6.2	Rachas de ceros y límites observados	8
7	Magnitud, dispersión y valores extremos	8
7.1	Media y mediana	8
7.2	Varianza muestral	9
7.3	Percentil 95 y máximo	9
7.4	Varianza sobre media y distribución de Poisson	9

8	Incidencia y comparación entre estados	10
8.1	Media semanal por año	10
9	Cómo leer las figuras del notebook	10
9.1	Escala logarítmica	10
9.2	Mapas de calor y escalas de color	11
10	Agregación meteorológica diaria a semanal	11
10.1	Comparación numérica	11
11	Rezagos y ventanas climáticas	12
11.1	Rezago	12
11.2	Definición de las ventanas	12
11.3	Valores ausentes al comienzo	12
12	Origen, objetivo y horizontes de pronóstico	13
12.1	No confundir origen y objetivo	13
13	Disponibilidad retrospectiva y disponibilidad real	13
13.1	Condiciones revisadas en el notebook	13
13.2	Conjunto de información en el origen	13
14	Entrenamiento, validación y prueba temporal	14
14.1	Por qué no repartir semanas al azar	14
14.2	Fuga de información	14
14.3	Evaluación retrospectiva y prueba no ciega	14
15	Covarianza y correlación de Pearson	15
15.1	Covarianza	15
15.2	Pearson	15
15.3	Transformación $\log(1 + Y)$	15
16	Correlación de Spearman y empates	15
17	Correlaciones con rezagos y sensibilidad	16
17.1	Pares válidos en entrenamiento	16
17.2	Dependencia y estacionalidad	16
17.3	Sensibilidad al margen	16
17.4	Límites de la interpretación	17
18	Reproducibilidad, archivos y decisiones pendientes	17
18.1	CSV y configuración JSON	17

18.2	Guía de lectura de las salidas	17
18.3	Decisiones necesarias antes de ajustar modelos	18
18.4	Preparación para la siguiente etapa: error de pronóstico	18
19	Ejemplo integrado de una fila candidata	18
20	Lista de comprobación para estudiar	19

1 Propósito del diagnóstico

Un diagnóstico temporal revisa si los datos permiten formular y evaluar una pregunta de pronóstico de manera coherente. Antes de elegir un modelo, debemos saber qué representa una observación, qué semanas están cubiertas, cuándo se actualizaron los archivos y qué información podría usarse al pronosticar.

En este proyecto, la unidad principal es la **semana–estado**. El notebook no ajusta modelos. Construye el calendario de evaluación y revisa candidatos a predictores, conservando las decisiones pendientes en la configuración final.

Tres comprobaciones diferentes

Estructura: el archivo tiene fechas, estados y valores utilizables. **Consistencia:** sus valores respetan una regla, como la agregación semanal. **Disponibilidad:** el dato podía conocerse en una fecha concreta. Un dato puede superar las dos primeras comprobaciones sin superar la tercera.

2 Notación y estructura de las matrices

Sea s un estado y t una etiqueta semanal. Denotaremos por $Y_{s,t}$ los casos confirmados registrados con inicio de síntomas en la semana correspondiente. En el pipeline del proyecto, los confirmados se seleccionaron mediante el estatus numérico 2. Esta es la definición operativa utilizada en sus archivos.

La matriz de casos tiene la forma

$$\mathbf{Y} = (Y_{s,t})_{t,s},$$

con filas ordenadas por fecha y columnas por estado. La incidencia y las variables meteorológicas tienen matrices con la misma disposición.

Las matrices originales tienen 334 semanas y 32 estados, desde el domingo 5 de enero de 2020 hasta el domingo 24 de mayo de 2026. La suma de la matriz de casos es 242 999. Este total describe los registros conservados por el pipeline; no equivale necesariamente al total de todas las infecciones ocurridas.

2.1 Alineación

Dos matrices están alineadas si coinciden sus fechas, estados y orden. La igualdad del tamaño no es suficiente.

Ejemplo: Mismo tamaño, distinto significado

Una matriz tiene columnas [Colima, Veracruz] y otra [Veracruz, Colima]. Ambas tienen dos columnas, pero unir las por posición asignaría el clima de Veracruz a los casos de Colima. Debemos comparar las etiquetas antes de combinar valores.

2.2 Controles estructurales

Se revisan fechas interpretables, orden creciente, duplicados, separación semanal, valores numéricos y finitos. En casos e incidencia también interesa comprobar no negatividad; los casos deben ser conteos enteros.

Un valor *finito* no es infinito ni un valor ausente. Sin embargo, superar estos controles no demuestra que un valor sea correcto físicamente. Por ejemplo, una temperatura extrema requiere una revisión distinta de la mera conversión a número. Los códigos de ausencia, como -999 cuando se utilizan, tampoco deben tratarse como mediciones.

3 Calendario semanal y cobertura

3.1 Etiqueta y días incluidos

Las semanas se construyen de lunes a domingo y se etiquetan con el domingo final. Si t es ese domingo, el conjunto de días es

$$W_t = \{t - 6, t - 5, \dots, t\}.$$

Por tanto, $Y_{s,t}$ agrega los registros de los siete días de W_t . En pandas esta convención corresponde a un calendario W-SUN, con los límites de agregación establecidos explícitamente.

Ejemplo: Una semana que cruza de año

La etiqueta 2020-01-05 representa los días 2019-12-30 a 2020-01-05. Su año de etiqueta es 2020, aunque incluye dos días de 2019. El año de etiqueta no debe confundirse con el año de síntomas de cada registro ni con una numeración epidemiológica o ISO que no se haya definido.

3.2 Regularidad del calendario

En una serie semanal regular,

$$t_i - t_{i-1} = 7 \text{ días}.$$

La secuencia de fechas esperadas permite detectar semanas ausentes. Que no haya valores nulos en una matriz no asegura regularidad: podría faltar una fila completa.

3.3 Semanas parcialmente cubiertas

Si el rango observado de síntomas es $[a, b]$, la intersección de una semana con ese rango tiene

$$D_t = \max \{0, \min(t, b) - \max(t - 6, a) + 1\}$$

días, contando ambos extremos. La expresión se interpreta en días.

En el proyecto, el rango observado es 2020-01-01 a 2026-05-20. La primera semana incluye cinco días de ese rango y la última tres. Sus conteos son 175 y 9, respectivamente.

Cobertura y ausencia de eventos

El rango entre el primer y el último síntoma registrado permite identificar extremos que deben revisarse. Por sí solo no demuestra que todos los días interiores estuvieran observados ni que un día sin registros careciera de casos. La cobertura del sistema requiere información adicional sobre la fuente.

4 Fechas de los archivos y consolidación

4.1 Tres fechas con funciones diferentes

Fecha	Función en el diagnóstico
Inicio de síntomas	Ubica temporalmente el evento registrado.
Actualización interna	Es la fecha declarada dentro del archivo; se utiliza como referencia para las máscaras.
Fecha del ZIP	Es la fecha inferida del nombre o del manifiesto de publicación.

Estas fechas pueden diferir. Un archivo publicado más tarde puede conservar una actualización interna anterior. La publicación reciente no garantiza que su contenido también lo sea.

Ejemplo: Archivo de 2024

El ZIP seleccionado tiene fecha 2024-12-19 y todos sus registros declaran actualización 2024-12-16. El último síntoma entre los confirmados temporalmente consistentes es 2024-12-11. No podemos interpretar los días restantes de diciembre sin confirmados como evidencia de ausencia de dengue.

4.2 Consistencia temporal

Una regla básica compara síntomas con actualización:

$$\text{fecha de síntomas} \leq \text{fecha de actualización.}$$

También se compara con la fecha del ZIP. Un síntoma posterior señala una inconsistencia que requiere revisión; no autoriza a corregir la fecha por suposición.

Los archivos originales de 2024 y 2025 tienen un registro de síntomas posterior a ambas fechas. Ninguno es confirmado. Los conteos de archivos originales y de la matriz analítica pueden diferir por la limpieza geográfica previa.

4.3 Retrasos, revisiones y extremos recientes

Entre los síntomas, la notificación y la clasificación de un caso pueden pasar días. Por ello, los conteos recientes pueden revisarse en versiones posteriores. El descenso al final de una serie puede mezclar variación real y retraso de registro o confirmación. Se trata de una forma de incompletitud hacia el extremo reciente; este notebook no estima una distribución de retrasos ni aplica un modelo de corrección de esos retrasos.

El último día con confirmados tampoco identifica automáticamente el último día cubierto: puede haber días legítimamente sin eventos.

4.4 Años completos y datos consolidados

Un año calendario completo, un calendario semanal completo y un conjunto de registros consolidado son propiedades distintas. El diagnóstico utiliza las últimas versiones anuales seleccionadas, pero no las considera necesariamente definitivas. Además, la base analítica final no conserva la procedencia de cada registro: no permite reconstruir qué se sabía en cada publicación histórica.

5 Máscaras de admisión y márgenes

5.1 Periodo de estudio

Para el diagnóstico comparativo se consideran semanas cuyos siete días están dentro de 2020-01-01 a 2025-12-31. Quedan 312 etiquetas, desde 2020-01-12 hasta 2025-12-28. El año 2026 permanece en las matrices originales, pero no forma parte de estas etapas de evaluación.

5.2 Definición de una máscara

Una máscara es un indicador booleano: *verdadero* si una observación cumple una condición y *falso* si no la cumple.

Sea A_y la actualización interna del archivo seleccionado para el año y y sea m un margen en días. Dentro del periodo de estudio, la regla utilizada es

$$M_m(t) = \mathbf{1}\left\{d \leq A_{\text{año}(d)} - m \quad \text{para todo } d \in W_t\right\}.$$

Cada día se compara con la actualización de **su propio año**. Esto es especialmente importante en semanas que cruzan el 31 de diciembre.

El margen 0 elimina las semanas que sobrepasan las actualizaciones. Los márgenes positivos retroceden el límite para estudiar la sensibilidad a los extremos.

Ejemplo: Una semana admitida con margen 28

Con actualización 2024-12-16 y margen de 28 días, el límite es 2024-11-18. La semana que termina el domingo 2024-11-17 queda antes del límite y puede admitirse. La que termina el 2024-11-24 lo sobrepasa y no se admite.

Las máscaras son anidadas:

$$M_{42}(t) \leq M_{28}(t) \leq M_{14}(t) \leq M_0(t).$$

En el proyecto se admiten 300, 288, 276 y 264 semanas, respectivamente.

Lo que un margen no demuestra

Un margen es un escenario de análisis, no una estimación del retraso real. Admitir una semana con 28 días no demuestra que esté consolidada. Tampoco demuestra que sus valores finales se conocieran en la fecha de un pronóstico. La sensibilidad a márgenes y la disponibilidad en tiempo real son problemas diferentes.

5.3 Conservar fechas y distinguir estados del dato

No se deben confundir tres situaciones: cero observado, valor ausente y semana no admitida. Reemplazar las dos últimas por cero cambia el significado. En las gráficas, una semana no admitida puede representarse como un hueco o con un color específico. Los rezagos se calculan sobre el calendario original.

Ejemplo: El peligro de comprimir la serie

Las etiquetas 7, 14 y 21 de enero tienen conteos 2, 5 y 9. Si excluimos el 14 de enero y desplazamos después una fila, el antecedente de 9 será 2, aunque están separados por dos

semanas. En el calendario completo, el rezago de una semana apunta al 14 de enero y debe marcarse como no admitido.

6 Ceros y rachas

6.1 Frecuencia de ceros

Para un estado y una máscara, sean n las semanas consideradas y n_0 las semanas admitidas con cero casos. La frecuencia porcentual es

$$p_0 = 100 \frac{n_0}{n}.$$

Al cambiar la máscara cambian tanto el numerador como el denominador.

Ejemplo: Porcentaje sencillo

Los conteos $[0, 0, 3, 0, 2]$ tienen tres ceros en cinco semanas: $p_0 = 60\%$. Si la primera semana no se admite, quedan dos ceros en cuatro semanas: $p_0 = 50\%$. No se modificaron los conteos; cambió el conjunto evaluado.

Un cero en esta base significa que no se conservaron confirmados para esa combinación semana-estado. No permite concluir ausencia de infección, de transmisión o de subregistro.

6.2 Rachas de ceros y límites observados

Una racha es una secuencia de semanas consecutivas admitidas con cero casos. Una semana con casos o una semana no admitida interrumpe la secuencia.

La racha puede estar limitada por el borde del periodo o por una exclusión. En ese caso solo conocemos su duración dentro del segmento observable; no la duración completa del proceso que podría continuar fuera de él.

Ejemplo: Racha y exclusión

En $[0, 0, \text{no admitida}, 0, 0, 0, 2]$ hay dos rachas observadas: dos y tres semanas. No corresponde unir las rachas en una racha de cinco. La exclusión representa un límite de observación.

Tlaxcala tiene cerca de 92% de ceros en las 312 semanas, mientras que Veracruz tiene cerca de 4.5%. Estas diferencias motivan un análisis por estado, pero no explican por sí solas sus causas.

7 Magnitud, dispersión y valores extremos

7.1 Media y mediana

Para los conteos admitidos $y_1, \dots, y_n$, la media es

$$\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i.$$

La mediana es el valor central de los datos ordenados; con un número par de datos se promedian los dos valores centrales. La media responde a todos los valores y puede aumentar mucho por brotes intensos; la mediana resume el centro de la distribución ordenada.

Ejemplo: Un pico cambia la media

En $[0, 0, 1, 1, 18]$, la media es 4 y la mediana 1. La media no representa una semana típica de esta secuencia. Ambas medidas son útiles y responden a preguntas distintas.

7.2 Varianza muestral

La varianza usada en el notebook tiene denominador $n - 1$:

$$s_y^2 = \frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2.$$

Describe la dispersión respecto a la media. Su raíz cuadrada es la desviación estándar. El denominador coincide con `ddof=1`; la interpretación descriptiva no exige que las semanas sean independientes.

Ejemplo: Media y varianza

Para $[0, 0, 0, 4]$, $\bar{y} = 1$ y

$$s_y^2 = \frac{1 + 1 + 1 + 9}{3} = 4.$$

La varianza supera la media: la serie combina varias semanas sin casos y un pico.

7.3 Percentil 95 y máximo

El percentil 95 señala un umbral alto de la distribución ordenada. Con pocos datos puede obtenerse por interpolación y no tiene que coincidir con un valor observado. El máximo es el mayor conteo. Si el máximo ocurre varias veces, el notebook registra la primera fecha en la que aparece.

7.4 Varianza sobre media y distribución de Poisson

Se calcula el cociente descriptivo

$$F = \frac{s_y^2}{\bar{y}}, \quad \bar{y} > 0.$$

Si la media es cero, el cociente se deja sin definir. Una variable Poisson con parámetro fijo λ satisface $\mathbb{E}(Y) = \text{Var}(Y) = \lambda$.

Un cociente grande describe dispersión marginal superior a la media. No demuestra automáticamente sobredispersión *condicional* de un modelo: la estacionalidad, las tendencias y los cambios entre años también aumentan la dispersión al juntar semanas. Por ejemplo, si $Y \mid \lambda$ es Poisson y λ cambia entre semanas, entonces

$$\text{Var}(Y) = \mathbb{E}(\lambda) + \text{Var}(\lambda).$$

Puede haber dispersión marginal elevada sin que cada distribución condicional incumpla la igualdad Poisson. Por ello, ni este cociente ni muchos ceros bastan para elegir una binomial negativa o un modelo con inflación de ceros.

8 Incidencia y comparación entre estados

Sea $P_{s,t}$ la población utilizada como denominador. La incidencia semanal por 100 000 habitantes se representa mediante

$$I_{s,t} = 100\,000 \frac{Y_{s,t}}{P_{s,t}}.$$

Para interpretar o reproducir la incidencia hay que conocer el origen y la vigencia de las poblaciones del pipeline. No se deben inferir esos denominadores solo a partir de las tablas descriptivas.

Ejemplo: Más casos no siempre significa más incidencia

El estado A registra 100 casos en una población de 1 000 000: incidencia 10. El estado B registra 50 casos en una población de 200 000: incidencia 25. A tiene más casos; B tiene más casos por cada 100 000 habitantes.

Con población positiva y sin efectos de redondeo, casos e incidencia son cero en las mismas posiciones. El notebook comprueba esta correspondencia.

8.1 Media semanal por año

Si $\mathcal{T}_y$ contiene las semanas admitidas con etiqueta en el año y , la media anual de incidencias semanales es

$$\bar{I}_{s,y} = \frac{1}{|\mathcal{T}_y|} \sum_{t \in \mathcal{T}_y} I_{s,t}.$$

Es una media sobre las semanas seleccionadas, no incidencia acumulada anual. El margen 0 utiliza 51, 49, 49, 51, 50 y 50 semanas para 2020 a 2025. Los promedios normalizan por el número de semanas, pero no eliminan diferencias en qué partes de la estación de transmisión quedan incluidas.

Si el denominador poblacional fuera constante y los periodos fueran compatibles, sumar incidencias semanales correspondería a acumular casos divididos por esa población. Aun así, sumar solo semanas admitidas no recupera automáticamente un año completo, ni resuelve las semanas que cruzan de año.

9 Cómo leer las figuras del notebook

Las figuras 1–4 muestran la serie nacional, los cortes y la admisión de semanas. La figura 5 resume porcentajes de ceros y la 6 ubica los ceros y las exclusiones en el calendario. La figura 7 compara media y varianza; las figuras 8–9 describen incidencia. La 10 ubica ventanas y objetivos, y la 11 compara correlaciones. Su lectura exige atender a las siguientes convenciones.

9.1 Escala logarítmica

En un eje logarítmico, distancias iguales representan razones iguales. Pasar de 1 a 10 ocupa la misma distancia que pasar de 10 a 100. Esta escala facilita comparar estados con magnitudes muy diferentes. El cero no puede dibujarse directamente en un eje logarítmico.

En la figura 7, la línea $\text{varianza} = \text{media}$ es una referencia numérica. Los puntos superiores tienen mayor varianza que media. Como los ejes tienen límites independientes, la igualdad no debe juzgarse por un supuesto ángulo visual de 45 grados.

9.2 Mapas de calor y escalas de color

Un mapa de calor asigna un color a cada celda. Hay que distinguir entre una escala numérica, como porcentajes, y una escala categórica, como cero, casos y semana no admitida. El color de una exclusión no representa cero casos.

La figura 9 utiliza una normalización de potencia para hacer visibles valores pequeños. Si $v_{\min} = 0$, la transformación de color es proporcional a $(v/v_{\max})^{0.45}$. La escala de color es no lineal, pero las cifras anotadas son las incidencias originales.

En la figura 8 cada estado tiene su propia escala vertical: conviene comparar formas y fechas; para comparar magnitudes hay que leer los ejes.

10 Agregación meteorológica diaria a semanal

Sea $x_{s,d}$ un valor meteorológico diario. Se requieren siete observaciones válidas para una semana completa. Las operaciones utilizadas son:

Operación	Variables semanales
Media	T2M, RH2M, ALLSKY_SFC_SW_DWN, WS10M, GWETTOP, EVLAND.
Máximo	T2M_MAX: máximo de las temperaturas máximas diarias.
Mínimo	T2M_MIN: mínimo de las temperaturas mínimas diarias.
Suma	PRECTOTCORR: acumulado de precipitación diaria.

Las fórmulas correspondientes son

$$\bar{x}_{s,t} = \frac{1}{7} \sum_{d \in W_t} x_{s,d}, \quad x_{s,t}^{\max} = \max_{d \in W_t} x_{s,d}, \quad x_{s,t}^{\min} = \min_{d \in W_t} x_{s,d},$$
$$p_{s,t} = \sum_{d \in W_t} p_{s,d}.$$

Ejemplo: Precipitación semanal

Los valores diarios $[0, 2, 0, 5, 3, 0, 4]$ suman 14. La media diaria durante esa semana es 2. El acumulado semanal y la media diaria son cantidades distintas. Si faltara un día, una suma de los seis restantes no demostraría cobertura completa.

Para las 312 semanas y 32 estados se verifican $312 \times 32 = 9984$ valores por variable. Las nueve matrices coinciden con sus agregaciones reconstruidas. El clima proviene de un punto representativo por estado; no es necesariamente un promedio espacial ni describe todas las localidades del estado.

10.1 Comparación numérica

Los decimales calculados pueden diferir mínimamente por representación de punto flotante. Por eso se comprueba una tolerancia del tipo

$$|a - b| \leq \varepsilon_{\text{abs}} + \varepsilon_{\text{rel}}|b|,$$

con tolerancias absoluta y relativa pequeñas. Esta comprobación no sustituye la revisión de fechas, unidades y cobertura.

11 Rezagos y ventanas climáticas

11.1 Rezago

Para una serie semanal $X_{s,t}$, el rezago j en la fecha t es $X_{s,t-j}$, donde restar j significa retroceder $7j$ días. Un rezago de 52 semanas equivale a 364 días, no exactamente a un año calendario.

11.2 Definición de las ventanas

En una fecha origen o , la ventana $[a, b]$ contiene

$$X_{s,o-a}, X_{s,o-(a+1)}, \dots, X_{s,o-b}.$$

Tiene $L = b - a + 1$ semanas. Para temperatura y humedad:

$$V_{s,o}^{[a,b]} = \frac{1}{L} \sum_{j=a}^b X_{s,o-j}.$$

Para precipitación:

$$V_{s,o}^{[a,b]} = \sum_{j=a}^b p_{s,o-j}.$$

La ventana `t0` es la identidad: toma $X_{s,o}$.

Ventana	a	b	Semanas incluidas
<code>t0</code>	0	0	Semana que termina en el origen.
<code>11_2</code>	1	2	Dos semanas anteriores.
<code>13_6</code>	3	6	Cuatro semanas, de tres a seis antes.
<code>17_12</code>	7	12	Seis semanas, de siete a doce antes.

Ejemplo: Una ventana de dos semanas

Si las temperaturas medias de las dos semanas anteriores son 24 y 26, `t2m_11_2` vale 25. Si sus precipitaciones semanales son 10 y 30, `precip_11_2` vale 40. El promedio conserva la interpretación de temperatura; la suma representa lluvia acumulada durante dos semanas.

11.3 Valores ausentes al comienzo

Al iniciar una serie no existen todos los antecedentes. Para una ventana cuyo rezago máximo es b , las primeras b filas carecen de entradas suficientes. Con 32 estados, se esperan $32b$ valores ausentes: 64 para `11_2`, 192 para `13_6` y 384 para `17_12`.

La reconstrucción combina desplazamiento y ventana móvil: `shift(a)` seguido de `rolling(b-a+1)` con todas las entradas requeridas. No se rellenan los antecedentes inexistentes con cero.

Al exigir que tanto la fecha de la ventana como todos sus antecedentes estén en el periodo con comprobación diaria, quedan 312, 310, 306 y 300 semanas verificables, respectivamente. Estos conteos no deben confundirse con el número total de filas de cada archivo ni con la disponibilidad de ventanas en 2024–2025.

12 Origen, objetivo y horizontes de pronóstico

El **origen** o es la fecha desde la que se emite un pronóstico. El **objetivo** q es el domingo que etiqueta la semana a predecir. Para un horizonte de h semanas,

$$q = o + 7h \text{ días}, \quad \hat{Y}_{s,q|o} = \text{pronóstico de } Y_{s,q} \text{ emitido desde } o.$$

El notebook considera $h = 1$ y $h = 4$. Cada objetivo es una sola semana, no un acumulado de h semanas.

Ejemplo: Fechas concretas

Con origen domingo 2024-06-02, el objetivo de una semana es 2024-06-09 y el de cuatro semanas es 2024-06-30. En el segundo caso se pronostican los casos del 24 al 30 de junio. En ambos, $\mathfrak{t}0$ describe la semana del 27 de mayo al 2 de junio, que termina en el origen.

Los antecedentes de casos candidatos son

$$Y_{s,o}, \quad Y_{s,o-1}, \quad Y_{s,o-2}, \quad Y_{s,o-3}.$$

En esta fórmula los índices se expresan en semanas. El rezago cero de casos también requiere una regla de disponibilidad; terminar una semana no garantiza que sus confirmados ya sean conocidos.

12.1 No confundir origen y objetivo

Las ventanas guardadas en la fila q describen antecedentes de q . Para pronosticar desde o se consultan las ventanas de la fila o . Usar $\mathfrak{t}0$ de q incorporaría clima de la semana futura a predecir.

13 Disponibilidad retrospectiva y disponibilidad real

13.1 Condiciones revisadas en el notebook

Un candidato tiene cuatro antecedentes de casos admitidos si

$$C_m(o) = \prod_{j=0}^3 M_m(o-j) = 1.$$

Tiene clima completo para el estado s si sus doce valores de ventanas en o son finitos. Denotemos esa condición por $K_s(o)$. El indicador conjunto es

$$J_{s,m}(o) = C_m(o)K_s(o).$$

Todos los candidatos se conservan, aunque $J = 0$. Los indicadores permiten revisar posteriormente el motivo de no cumplimiento.

Hay 752 candidatos de fecha–escenario–horizonte. Cada uno se expande a los 32 estados: $752 \times 32 = 24064$ filas. Un mismo objetivo aparece en diferentes escenarios; 752 no es el número de fechas distintas. El clima no agrega exclusiones en estos candidatos.

13.2 Conjunto de información en el origen

Sea $\mathcal{F}_o$ la información realmente accesible al emitir el pronóstico. Una predicción operativa debe poder calcularse utilizando solo $\mathcal{F}_o$. Un archivo descargado después del origen puede contener revisiones que no estaban en ese conjunto de información, aunque los síntomas o el clima sean anteriores.

Ejemplo: Un dato histórico que todavía no se conocía

Al pronosticar el 2 de junio, los casos finales de la semana que termina ese día podrían publicarse o confirmarse después. Usar en el origen su valor final recuperado meses más tarde no reproduce necesariamente un pronóstico real. Esto puede ocurrir aun cuando el margen anual admita esa semana.

Un protocolo futuro podría usar versiones históricas de publicaciones o imponer retrasos de disponibilidad por fuente. Estos retrasos deben justificarse; no se deducen automáticamente de los márgenes de admisión del notebook.

14 Entrenamiento, validación y prueba temporal

Etapas	Años	Semanas	Propósito
Entrenamiento	2020–2023	208	Ajustar relaciones y parámetros.
Validación	2024	52	Comparar configuraciones y decidir.
Prueba	2025	52	Evaluar la configuración elegida.

Estos son conteos del calendario antes de las máscaras. Con margen 0 se admiten 200, 50 y 50 semanas, respectivamente. La etapa se asigna por la fecha objetivo; un objetivo de enero puede tener un origen en diciembre del año anterior.

14.1 Por qué no repartir semanas al azar

Semanas cercanas suelen compartir estacionalidad y nivel de actividad. Un reparto aleatorio puede colocar información del futuro en el entrenamiento e intercalar semanas muy similares entre etapas. El corte cronológico representa mejor la pregunta de predecir un periodo posterior a partir de información anterior.

14.2 Fuga de información

Existe fuga cuando se usa información que no debería intervenir en una etapa o en un origen. Ejemplos: seleccionar predictores según el resultado de prueba, normalizar con datos de todos los años, utilizar ventanas climáticas del objetivo o emplear versiones de casos publicadas después del origen en una evaluación presentada como operativa.

Los escaladores, imputadores y demás transformaciones aprendidas deben ajustarse con el entrenamiento correspondiente. En una evaluación con actualización, cada ajuste debe respetar su propio límite temporal y la disponibilidad de sus objetivos de entrenamiento.

14.3 Evaluación retrospectiva y prueba no ciega

El conjunto actual usa cortes anuales retrospectivos. La separación por años no convierte por sí sola esos datos en versiones disponibles en cada origen. Además, se exploró 2025 en el diagnóstico; por eso se mantiene como prueba temporal reservada, pero no completamente ciega. No se han ajustado modelos.

15 Covarianza y correlación de Pearson

15.1 Covarianza

Para pares (x_i, z_i) , $i = 1, \dots, n$, la covarianza muestral es

$$s_{xz} = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(z_i - \bar{z}).$$

Es positiva si desviaciones del mismo signo predominan, y negativa si predominan signos opuestos. Depende de las unidades de las variables.

15.2 Pearson

La correlación normaliza la covarianza:

$$r = \frac{s_{xz}}{s_x s_z} = \frac{\sum_i (x_i - \bar{x})(z_i - \bar{z})}{\sqrt{\sum_i (x_i - \bar{x})^2} \sqrt{\sum_i (z_i - \bar{z})^2}}.$$

Está entre -1 y 1 . Describe asociación lineal en la escala utilizada. Es indefinida si una variable es constante. No se necesita normalidad para calcular el coeficiente; las condiciones de una prueba inferencial son un asunto distinto.

Ejemplo: Cálculo manual

Para $x = [1, 2, 3]$ y $z = [2, 1, 3]$, ambas medias son 2. Las desviaciones son $[-1, 0, 1]$ y $[0, -1, 1]$. El numerador de la fórmula es 1 y cada suma de cuadrados vale 2. Por tanto, $r = 1/\sqrt{2 \cdot 2} = 0.5$.

15.3 Transformación $\log(1 + Y)$

En el notebook se utiliza

$$Z_{s,t} = \log(1 + Y_{s,t}).$$

El 1 permite transformar ceros. La transformación es creciente y comprime valores grandes: para casos 0, 1, 9 y 99 se obtienen aproximadamente 0, 0.693, 2.303 y 4.605. Pearson calculado sobre Z describe una relación en escala logarítmica transformada, no sobre los conteos originales.

Transformar no equivale a estabilizar todo

La transformación puede reducir la influencia de grandes brotes, pero no garantiza normalidad, independencia, estacionariedad ni varianza constante. Estas propiedades no se concluyen de haber aplicado `log1p`.

16 Correlación de Spearman y empates

Spearman es Pearson aplicado a los rangos de los valores:

$$\rho_S = \text{Corr}(R(X), R(Z)).$$

Los rangos representan posiciones en el orden de los datos. Si varias observaciones empatan, se les asigna el promedio de las posiciones ocupadas. Spearman describe asociación monotónica: si al aumentar una variable la otra tiende a aumentar o disminuir, aunque la relación no sea lineal.

Ejemplo: Rangos con ceros empatados

Para $[0, 0, 2, 5]$, los rangos son $[1.5, 1.5, 3, 4]$. Las dos observaciones cero ocupan conjuntamente las posiciones 1 y 2 y reciben su media, 1.5. Los valores $[0, 0, 1, 8]$ tienen los mismos rangos: su Spearman con la primera serie es 1, aunque las distancias numéricas sean diferentes.

La fórmula de Spearman basada solamente en diferencias de rangos y $1 - 6 \sum d_i^2 / [n(n^2 - 1)]$ requiere ausencia de empates. Como los casos tienen muchos ceros, la definición mediante correlación de rangos es la apropiada.

Una transformación estrictamente creciente como $\log(1 + Y)$ conserva los rangos y empates matemáticamente. Por eso Spearman sobre conteos y sobre esa transformación coincide, salvo efectos numéricos. Pearson sí puede cambiar.

Spearman tampoco es inmune a problemas de datos: muchos empates reducen la información de orden, y ambas correlaciones son indefinidas para series constantes.

17 Correlaciones con rezagos y sensibilidad

17.1 Pares válidos en entrenamiento

Se comparan los casos de t con los de $t - k$ para $k \in \{1, 2, 4, 8, 13, 26, 52\}$ semanas. Para un margen m , el conjunto de pares es

$$\mathcal{P}_{m,k} = \{t : t, t - k \text{ pertenecen al entrenamiento, } M_m(t) = M_m(t - k) = 1\}.$$

Sobre el mismo conjunto se calculan

$$r_{s,m,k} = \text{Corr}(\log(1 + Y_{s,t}), \log(1 + Y_{s,t-k})), \quad \rho_{s,m,k} = \text{Corr}(R(Y_{s,t}), R(Y_{s,t-k})).$$

Los rangos se calculan para los pares seleccionados en cada comparación.

Con margen 0 hay 196 pares para el rezago 1 y 147 para el rezago 52. Los conteos coinciden entre estados porque comparten las máscaras y no tienen valores ausentes de casos. Una correlación con pocos pares requiere más cautela que otra basada en muchos; el coeficiente solo no muestra esa diferencia.

17.2 Dependencia y estacionalidad

Una asociación positiva corta puede representar persistencia entre semanas cercanas. Una asociación a 52 semanas puede ser compatible con patrones anuales, pero no demuestra que se repitan de manera estable. Tendencias, brotes y cambios de nivel también afectan las correlaciones.

El cálculo del notebook es una correlación descriptiva entre pares filtrados; no es una estimación convencional de toda una ACF estacionaria ni una PACF. La PACF eliminaría efectos lineales de rezagos intermedios, operación que aquí no se realiza. Tampoco se ajusta por clima o por otras covariables.

17.3 Sensibilidad al margen

Para cada medida se compara el coeficiente con su referencia de margen 0:

$$\Delta_{s,m,k} = c_{s,m,k} - c_{s,0,k}, \quad D_{s,m,k} = |\Delta_{s,m,k}|.$$

La mediana de D entre estados resume un cambio típico, y el máximo ayuda a identificar excepciones. La mediana no implica que todos los estados sean estables.

En el rezago 1 y margen 42, las medianas del cambio absoluto son aproximadamente 0.012 para Pearson y 0.020 para Spearman. En el rezago 8 son 0.110 y 0.092. Los conjuntos de pares cambian con el margen: el cambio combina modificación del tamaño muestral y de las semanas incluidas, no un efecto causal del margen.

17.4 Límites de la interpretación

Una correlación no prueba causalidad. Un valor cercano a cero tampoco descarta toda relación no lineal. Las semanas tienen dependencia temporal, así que no se deben aplicar sin revisión pruebas que supongan pares independientes. El notebook no calcula valores p , intervalos inferenciales ni pruebas de estacionariedad. Una correlación alta no garantiza mejor pronóstico fuera del entrenamiento.

18 Reproducibilidad, archivos y decisiones pendientes

18.1 CSV y configuración JSON

Un CSV guarda una tabla: etiquetas, conteos, indicadores o resúmenes. El índice de fechas o estados debe exportarse como columna cuando aporta significado. El JSON guarda reglas y parámetros del diagnóstico. Un valor `null` significa aquí que una decisión sigue pendiente, no que se eligió cero.

Las tablas de candidatos conservan filas no admitidas y motivos de cumplimiento. Las tablas de correlaciones conservan el número de pares; las de ventanas, el número de valores comparados. Estos conteos permiten distinguir resultados numéricamente iguales obtenidos con alcances diferentes.

18.2 Guía de lectura de las salidas

Grupo de archivos	Pregunta que permite revisar
Auditoría anual	¿Qué fechas declaran los archivos y hay inconsistencias?
Calendario y máscaras	¿Qué semanas se admiten en cada escenario?
Ceros, rachas y magnitud	¿Cómo difieren los estados en actividad y dispersión?
Incidencia	¿Cómo cambia la comparación al considerar población?
Agregaciones y ventanas	¿Se reproducen los predictores desde sus entradas?
Candidatos y disponibilidad	¿Qué objetivos y antecedentes cumplen las reglas?
Correlaciones y sensibilidad	¿Cómo cambia la asociación temporal según medida, rezago y margen?
Configuración	¿Qué reglas se usaron y cuáles siguen pendientes?

18.3 Decisiones necesarias antes de ajustar modelos

1. Elegir y justificar el margen principal, manteniendo escenarios alternativos.
2. Definir la disponibilidad de casos y clima en cada origen.
3. Elegir predictores y transformaciones mediante entrenamiento y validación.
4. Establecer si el modelo será fijo o se actualizará, con qué datos y frecuencia.
5. Definir las métricas y modelos de referencia antes de evaluar la prueba.

Las cuatro primeras quedan pendientes en la configuración del notebook. Las métricas y modelos de referencia corresponden a la siguiente etapa.

18.4 Preparación para la siguiente etapa: error de pronóstico

Como conceptos adicionales para estudiar antes de modelar, si $e_i = y_i - \hat{y}_i$, el error absoluto medio es

$$\text{MAE} = \frac{1}{n} \sum_i |e_i|,$$

y la raíz del error cuadrático medio es

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_i e_i^2}.$$

RMSE da mayor peso a errores grandes. Una medida porcentual que divida por y_i necesita un tratamiento explícito de los ceros. Un modelo complejo debe compararse con referencias simples, como persistencia, utilizando las mismas filas evaluables y las mismas reglas de disponibilidad. Estas métricas no se han calculado como resultados del notebook 05.

19 Ejemplo integrado de una fila candidata

Supongamos un pronóstico para Colima con origen 2024-06-02, horizonte cuatro semanas y objetivo 2024-06-30. El objetivo pertenece a validación por su año.

1. Se comprueba que la semana objetivo esté admitida por el margen elegido.
2. Se buscan casos de las etiquetas 2024-06-02, 2024-05-26, 2024-05-19 y 2024-05-12, sin saltar filas excluidas.
3. Se comprueba la admisión de esas cuatro semanas.
4. Se consultan las doce ventanas climáticas en la fila 2024-06-02 para Colima.
5. Se verifica que sean finitas y se registra el cumplimiento conjunto.
6. Antes de modelar, se verifica qué versiones de esos datos podían conocerse en el origen y qué objetivos previos estaban disponibles para entrenar.

El notebook realiza los primeros cinco pasos como revisión retrospectiva de candidatos. El sexto requiere el protocolo de disponibilidad aún pendiente. La existencia de una fila candidata no equivale a haber emitido ni evaluado un pronóstico.

20 Lista de comprobación para estudiar

Al terminar este documento, el alumno debería poder:

- Distinguir fecha de síntomas, actualización y publicación.
- Explicar cómo una etiqueta dominical representa siete días.
- Diferenciar semana completa, semana admitida y dato consolidado.
- Construir una máscara sin confundir exclusiones con ceros.
- Calcular porcentajes de ceros, rachas, media, mediana y varianza.
- Interpretar incidencia y promedios semanales por año sin convertirlos automáticamente en acumulados anuales.
- Elegir la operación semanal y reconstruir una ventana climática.
- Ubicar origen, objetivo, horizonte y antecedentes en un calendario.
- Explicar por qué una evaluación cronológica puede seguir siendo retrospectiva.
- Calcular e interpretar Pearson y Spearman, incluyendo empates y series constantes.
- Leer una sensibilidad sin atribuir causalidad al margen.
- Identificar qué decisiones faltan antes de ajustar modelos.

Pregunta final de comprensión

Si todos los predictores existen en los archivos actuales y todas las comprobaciones numéricas coinciden, ¿qué falta para afirmar que el pronóstico podía emitirse realmente en su fecha origen? La respuesta debe distinguir consistencia de los datos, versiones históricas y disponibilidad de información.