

Clustering dinámico y pronóstico probabilístico por clúster con covariables exógenas en fenómenos eco-epidemiológicos o energéticos

Proyecto de Tesis

1 Introducción y Motivación

En muchos problemas reales de ciencia de datos con componente temporal y espacial (por ejemplo, incidencia de enfermedades transmitidas por vector como dengue, o demanda eléctrica por regiones), existe una fuerte **heterogeneidad** entre unidades geográficas: distintas regiones presentan estacionalidades, amplitudes de variación, tendencias y respuestas a covariables ambientales diferentes. En estos escenarios, entrenar un único modelo global tiende a producir dos efectos adversos: (i) un ajuste promedio que ignora patrones locales relevantes, y (ii) pronósticos que subestiman eventos extremos o picos regionales.

Una alternativa metodológicamente sólida es aplicar un enfoque “**segmentar y pronosticar**”: primero se identifican grupos (clústeres) de regiones con patrones similares usando características interpretables extraídas de las series (tendencia/estacionalidad/picos) y variables exógenas (clima, humedad, precipitación, temperatura, radiación, viento, etc.), y después se entrenan modelos especializados **por clúster**. Este enfoque permite: mejorar el desempeño predictivo, aumentar interpretabilidad (qué define a cada clúster), y generar recomendaciones por región/cluster.

Además, en aplicaciones operativas, no solo se requiere una predicción puntual, sino un **pronóstico probabilístico** con incertidumbre (bandas de predicción o “fan charts”), ya que decisiones reales (salud, energía, logística) necesitan conocer riesgo y rangos plausibles. Por ello, el proyecto enfatiza modelos que generen incertidumbre de manera explícita (p. ej. GLM/GLMM con conteos, modelos jerárquicos bayesianos, o enfoques cuantílicos).

2 Objetivos

2.1 Objetivo General

Diseñar e implementar un pipeline reproducible de **clustering dinámico** e **inferencias predictivas probabilísticas** por clúster, incorporando covariables exógenas,

y evaluarlo en un problema real (eco-epidemiológico o energético) mediante back-testing temporal riguroso.

2.2 Objetivos Específicos

1. **Construcción del panel temporal-geográfico:** integrar y limpiar datos reales en formato panel (unidad geográfica $\times$ tiempo), asegurando consistencia temporal, manejo de faltantes y trazabilidad de preprocesamiento.
2. **Extracción de features interpretables:** definir y calcular características de las series (tendencia, estacionalidad, amplitud estacional, semana pico, persistencia, variabilidad) y covariables ambientales con rezagos, incluyendo transformaciones y escalamiento.
3. **Clustering y selección del número de clústeres:** aplicar métodos de clustering (GMM, k-means, jerárquico, HDBSCAN) y seleccionar k usando criterios cuantitativos (BIC/ICL, silhouette, estabilidad por re-muestreo), buscando particiones interpretables y estables.
4. **Modelado por clúster con pronóstico probabilístico:** ajustar al menos dos familias de modelos por clúster:
 - **Modelos de conteo y sobredispersión:** Poisson vs NegBin (NB2), y/o GLMM con efectos aleatorios por región.
 - **Alternativa no lineal:** gradient boosting temporal o modelos estado-espacio como comparación (baseline avanzado).
5. **Evaluación con backtesting temporal:** diseñar un protocolo rolling-origin con horizontes múltiples (1, 4, 8 semanas/días) y métricas tanto puntuales como probabilísticas (cobertura, pinball loss, CRPS si aplica).
6. **Interpretación y comunicación:** producir visualizaciones y análisis interpretables: mapas de clústeres, perfiles estacionales por clúster, importancia de covariables, y reportes comparativos frente a un modelo global.

3 Marco Teórico

3.1 Representación de series temporales mediante descomposición y features

Las series temporales pueden describirse mediante componentes de tendencia, estacionalidad y residuales. Métodos como STL o descomposiciones similares permiten extraer *features* robustas que resumen el comportamiento de cada unidad geográfica. Se revisará:

- descomposición (tendencia/estacionalidad/residuo),
- features estacionales: amplitud, semana pico, fase,

- medidas de variabilidad y persistencia,
- tratamiento de escalas y normalización entre regiones.

3.2 Clustering: métodos, selección de k y estabilidad

Se estudiarán algoritmos de clustering y sus supuestos:

- **k-means:** particiones esféricas y sensibilidad a escala.
- **GMM:** clustering probabilístico con criterios BIC/ICL.
- **Jerárquico:** dendrogramas y linkage.
- **HDBSCAN:** densidad y detección de ruido (si se requiere).

Se enfatizará la importancia de **estabilidad** (robustez a inicialización y re-muestreo) y de interpretabilidad geográfica/climática del resultado.

3.3 Modelos para conteos, sobredispersión y estructura jerárquica

En aplicaciones como epidemiología (casos) o eventos discretos, la variable respuesta suele ser conteo. Se revisarán:

- Poisson y su limitación (varianza = media),
- NegBin (NB2) para sobredispersión,
- GLMM: efectos aleatorios para heterogeneidad entre regiones,
- covariables y rezagos (efectos retardados del clima).

3.4 Pronóstico probabilístico y evaluación

Además de métricas puntuales (MAE, RMSE, sMAPE), se revisarán métricas adecuadas para pronóstico probabilístico:

- cobertura de intervalos y calibración,
- pinball loss para cuantiles,
- CRPS (opcional) para distribuciones predictivas.

Se considerará validación temporal para evitar leakage.

4 Metodología

4.1 Selección del caso de estudio y estructura del panel

Se seleccionará una ruta principal (eco-epidemiología o energía), construyendo un panel:

$$\{(y_{i,t}, x_{i,t}) : i = 1, \dots, N, t = 1, \dots, T\},$$

donde i representa región/unidad y t el tiempo (semana, día u hora). Se definirá la granularidad temporal adecuada según disponibilidad y objetivo del pronóstico.

4.2 Preprocesamiento y construcción de covariables

- Alineación temporal y consistencia de calendarios.
- Manejo de faltantes: imputación simple/avanzada y diagnóstico.
- Transformaciones: log, escalamiento, winsorization si hay extremos.
- Covariables: climatología, movilidad u otras; creación de rezagos $x_{t-\ell}$ y promedios móviles.

4.3 Extracción de features para clustering

Se construirá una matriz de características por unidad i :

$$\mathbf{f}_i = (f_{i,1}, \dots, f_{i,p}),$$

donde $f_{i,\cdot}$ incluye estadísticos de estacionalidad (amplitud, semana pico), tendencia, dispersión, así como resúmenes climáticos. Se analizará correlación entre features y se aplicará reducción (PCA) si aporta estabilidad.

4.4 Clustering y selección de k

- Ajuste de múltiples candidatos (k-means, GMM, jerárquico, etc.).
- Selección de k por BIC/ICL (en GMM), silhouette, y estabilidad por remuestreo.
- Evaluación geográfica: coherencia espacial y perfiles diferenciados.

4.5 Modelado por clúster y pronóstico probabilístico

Una vez fijada la partición, se entrenará un modelo por clúster c :

$$y_{i,t} \mid c(i) = c \sim \mathcal{M}_c(x_{i,t}, y_{i,t-1}, \dots),$$

donde $\mathcal{M}_c$ será al menos:

- **GLM/GLMM Poisson vs NB2**: comparación explícita para sobredispersión.
- **Modelo alternativo**: boosting o estado-espacio para contrastar.

Se generarán predicciones con intervalos por horizonte.

4.6 Evaluación con backtesting temporal

Se aplicará rolling-origin:

- ventanas de entrenamiento crecientes o fijas,
- horizontes 1, 4, 8 (según problema),
- reporte por clúster y agregados (macro/micro).

Métricas puntuales: MAE/RMSE/sMAPE. Métricas probabilísticas: cobertura, pin-ball loss y/o CRPS.

4.7 Interpretabilidad y comunicación

Se producirán:

- mapas de clústeres y tamaños de clúster,
- perfiles estacionales promedio por clúster,
- importancia de covariables (según modelo),
- comparación contra baseline global y discusión de ventajas/limitaciones.

5 Resultados Esperados

- Un pipeline reproducible de **clustering + pronóstico por clúster**.
- Particiones estables e interpretables (con respaldo cuantitativo).
- Mejora consistente frente a un modelo global en métricas de pronóstico.
- Pronóstico probabilístico con calibración razonable y visualizaciones tipo fan charts.
- Producto académico: tesis completa y (idealmente) un manuscrito corto con resultados.

6 Herramientas y Tecnologías

- **Lenguaje:** Python.
- **Ciencia de datos:** pandas, numpy, scipy.
- **Clustering/ML:** scikit-learn, (opcional hdbscan).
- **Modelado:** statsmodels (GLM), PyMC/Stan (jerárquico opcional).
- **Mapas:** geopandas, shapely.
- **Visualización:** matplotlib.
- **Reproducibilidad:** git, entornos conda/pip, notebooks y reportes.

7 Sets de datos libres y reales (opciones)

El proyecto se basa en datos abiertos. Se recomienda elegir una ruta principal (A o B) y mantener la otra como extensión/validación.

7.1 Ruta A: Eco-epidemiología (incidencia + clima)

- **Incidencia (dengue u otra):** series semanales por región (estado/municipio) obtenibles de portales oficiales abiertos (según disponibilidad).
- **Clima y covariables: NASA POWER:** temperatura, humedad relativa, precipitación, radiación, viento, VPD, con posibilidad de rezagos.
- **Geometrías:** GeoJSON/shapefiles abiertos para mapas y análisis espacial.

7.2 Ruta B: Energía (demanda eléctrica + clima)

- **ENTSO-E:** demanda y generación eléctrica (resolución horaria/diaria) por país/región en Europa.
- **Meteorología: NASA POWER o NOAA:** variables para explicar patrones y eventos extremos.
- **Eventos de interés:** olas de calor/frío, periodos vacacionales, cambios en consumo (según región).

7.3 Ruta C (extensión opcional): movilidad como covariable

- **Google Community Mobility Reports:** series por región/categoría para enriquecer el modelo (particularmente útil en salud/contaminación).

Nota: en la fase inicial se realizará una exploración rápida para seleccionar la ruta definitiva considerando: cobertura temporal suficiente, calidad de datos, y relevancia del problema de pronóstico.

8 Bibliografía (base sugerida)

- Hyndman, R. J., & Athanasopoulos, G. *Forecasting: Principles and Practice*.
- McCullagh, P., & Nelder, J. *Generalized Linear Models*.
- Bishop, C. *Pattern Recognition and Machine Learning* (GMM y modelos probabilísticos).
- Hastie, Tibshirani, & Friedman. *The Elements of Statistical Learning*.